



UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO

CAMPUS PAU DOS FERROS

BACHARELADO EM ENGENHARIA DE COMPUTAÇÃO

**CLASSIFICAÇÃO DE DOENÇA CARDÍACA UTILIZANDO REGRESSÃO
LOGÍSTICA COM BASE EM DADOS CLÍNICOS**

JOSÉ FERREIRA SOUSA NETO

TÚLIO GOMES DE ARAÚJO FEITOSA

Pau dos Ferros – RN

Abril de 2026

JOSÉ FERREIRA SOUSA NETO

TÚLIO GOMES DE ARAÚJO FEITOSA

**CLASSIFICAÇÃO DE DOENÇA CARDÍACA UTILIZANDO REGRESSÃO
LOGÍSTICA COM BASE EM DADOS CLÍNICOS**

Relatório apresentado na disciplina de Sistemas Inteligentes como requisito para compor parte da nota da primeira unidade. Professor: Dr. Pedro Thiago Valério de Souza.

PAU DOS FERROS – RN

Abril de 2026

Sumário

1	Pré-processamento dos Dados	4
2	Treinamento do Modelo	4
3	Avaliação do Modelo	5
4	Conclusão	6

1 Pré-processamento dos Dados

O conjunto de dados utilizado possui 303 pacientes e 13 variáveis clínicas. Inicialmente, foi realizada a verificação de valores nulos, sendo identificados dados ausentes nas variáveis *ca* e *thal*. Para garantir a integridade do conjunto de dados, foi aplicada imputação utilizando a mediana de cada variável, resultando na substituição de 4 valores nulos em *ca* e 2 valores nulos em *thal*. Após esse processo, o dataset passou a não apresentar valores ausentes.

Em seguida, foi realizada a binarização da variável alvo, originalmente composta por valores de 0 a 4. Os dados foram convertidos para uma representação binária, onde 0 indica ausência de doença e 1 indica presença de doença. Após a transformação, observou-se uma distribuição de 164 pacientes sem doença e 139 pacientes com doença.

Posteriormente, os dados foram divididos em conjuntos de treino e teste na proporção de 80% e 20%, respectivamente, utilizando o parâmetro *stratify* para preservar a proporção entre as classes. O conjunto de treino ficou com 242 amostras, enquanto o conjunto de teste ficou com 61 amostras, mantendo proporções praticamente idênticas de pacientes com doença em ambos os conjuntos.

Por fim, foi realizado o escalonamento das variáveis numéricas contínuas (*age*, *trestbps*, *chol*, *thalach* e *oldpeak*) utilizando o método *StandardScaler*, garantindo que essas variáveis apresentassem média zero e desvio padrão unitário, o que contribui para melhor desempenho do modelo de regressão logística.

2 Treinamento do Modelo

Foi utilizado o algoritmo de regressão logística, implementado na biblioteca *scikit-learn*, com os parâmetros especificados: *solver = liblinear*, *random_state = 42* e *max_iter = 1000*. O modelo convergiu rapidamente, necessitando de apenas 5 iterações para atingir a convergência.

O modelo gerado possui 13 coeficientes, correspondentes às variáveis de entrada, além de um intercepto. A equação do modelo pode ser interpretada como uma combinação linear das variáveis, cujos pesos indicam a influência de cada característica na probabilidade de presença de doença cardíaca.

Variável	Coefficiente	Interpretação
age	-0.1093	Influência negativa fraca
sex	0.8015	Influência positiva forte
cp	0.2024	Influência positiva moderada
trestbps	0.2226	Influência positiva moderada
chol	0.1459	Influência positiva fraca
fbs	-0.3968	Influência negativa moderada
restecg	0.1712	Influência positiva fraca
thalach	-0.5284	Influência negativa moderada
exang	0.7985	Influência positiva forte
oldpeak	0.4028	Influência positiva moderada
slope	-0.1400	Influência negativa fraca
ca	0.9957	Influência positiva muito forte
thal	0.2879	Influência positiva moderada

Tabela 1: Coeficientes do modelo de regressão logística

Observa-se que as variáveis *ca* e *sex* apresentam os maiores coeficientes positivos, indicando forte relação com a presença de doença cardíaca. Por outro lado, a variável *thalach* apresenta coeficiente negativo relevante, sugerindo que maiores valores dessa variável estão associados à menor probabilidade de doença.

3 Avaliação do Modelo

O modelo foi avaliado utilizando o conjunto de teste por meio de métricas clássicas de classificação. Os resultados indicam um desempenho bastante satisfatório, com alta capacidade de discriminação entre pacientes com e sem doença cardíaca.

Métrica	Valor	Interpretação
Acurácia	0.8689	Alto desempenho geral
Precisão	0.8125	Boa confiabilidade nas previsões positivas
Recall	0.9286	Excelente detecção de pacientes doentes
F1-score	0.8667	Equilíbrio entre precisão e recall
AUC	0.9545	Excelente capacidade de discriminação

Tabela 2: Métricas de avaliação do modelo

Além disso, a matriz de confusão indica que o modelo apresentou poucos erros, com ape-

nas 2 falsos negativos e 6 falsos positivos, demonstrando elevada sensibilidade na identificação de pacientes com doença.

4 Conclusão

Os resultados obtidos demonstram que o modelo de regressão logística é altamente eficaz na tarefa de classificação da presença de doença cardíaca. A elevada AUC indica excelente capacidade de separação entre as classes, enquanto o alto valor de recall evidencia a eficiência do modelo na identificação de pacientes realmente doentes, aspecto fundamental em aplicações médicas.

Apesar de uma leve presença de falsos positivos, o modelo mantém um bom equilíbrio entre precisão e sensibilidade, conforme indicado pelo F1-score. Dessa forma, conclui-se que o modelo é adequado para auxiliar na triagem de pacientes, podendo servir como ferramenta de apoio à decisão em contextos clínicos.