



UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO
CAMPUS PAU DOS FERROS
BACHARELADO EM ENGENHARIA DE COMPUTAÇÃO

CLASSIFICAÇÃO IONOSFÉRICA UTILIZANDO REDE ADALINE

JOSÉ FERREIRA SOUSA NETO
TÚLIO GOMES DE ARAÚJO FEITOSA

Pau dos Ferros – RN

Maio de 2026

JOSÉ FERREIRA SOUSA NETO

TÚLIO GOMES DE ARAÚJO FEITOSA

CLASSIFICAÇÃO IONOSFÉRICA UTILIZANDO REDE ADALINE

Relatório apresentado na disciplina de Sistemas Inteligentes como requisito para compor parte da nota da segunda unidade. Professor: Dr. Pedro Thiago Valério de Souza.

PAU DOS FERROS – RN

Maio de 2026

Sumário

1	Preparação dos Dados	4
2	Estudo da Taxa de Aprendizagem	5
3	Treinamento e Avaliação do Modelo	6
4	Discussão e Conclusão	7

1 Preparação dos Dados

O conjunto de dados utilizado foi o *Ionosphere Dataset*, disponibilizado no repositório UCI Machine Learning Repository. O dataset possui 351 amostras e 34 atributos contínuos relacionados a sinais de radar utilizados para monitoramento ionosférico. A variável-alvo possui duas classes: *good*, indicando presença de estrutura ionosférica coerente, e *bad*, indicando ausência dessa estrutura.

Inicialmente, realizou-se a recodificação do rótulo de classe em valores bipolares, conforme solicitado na atividade. A classe *good* foi convertida para +1 e a classe *bad* para -1. Após a transformação, observou-se a seguinte distribuição:

- **good (+1):** 225 amostras
- **bad (-1):** 126 amostras

Posteriormente, foi realizada uma verificação de atributos constantes. Detectou-se que o atributo *Attribute2* possuía valor constante em todas as amostras e, portanto, foi removido do conjunto de dados, reduzindo a dimensionalidade de 34 para 33 atributos efetivos. Também foi verificada a presença de valores ausentes, não sendo encontrado nenhum valor nulo no dataset.

Em seguida, os dados foram divididos em conjuntos de treino e teste utilizando divisão estratificada na proporção de 80% para treino e 20% para teste. O conjunto de treino ficou composto por 280 amostras e o conjunto de teste por 71 amostras. A estratificação preservou adequadamente a proporção das classes em ambos os subconjuntos:

- **Treino:** 63,93% da classe *good* e 36,07% da classe *bad*
- **Teste:** 64,79% da classe *good* e 35,21% da classe *bad*

Após a divisão dos dados, foi aplicada a normalização utilizando padronização Z-score. Essa etapa é fundamental para o treinamento da Rede Adaline, pois a atualização dos pesos pela regra Delta depende diretamente da magnitude das entradas. A regra de atualização é dada por:

$$\Delta w = \eta(d - y)x$$

onde η representa a taxa de aprendizagem, d o valor desejado, y a saída da rede e x o vetor de entrada.

Sem normalização, atributos com escalas muito maiores dominariam o cálculo dos gradientes, causando atualizações desproporcionais dos pesos e instabilidade no processo de aprendizagem. A padronização Z-score transforma cada atributo para média aproximadamente zero e desvio padrão unitário, garantindo que todas as variáveis contribuam de maneira equili-

brada para o treinamento da rede.

Após a normalização, verificou-se que as médias das features ficaram próximas de zero e os desvios padrão próximos de um, indicando que o pré-processamento foi realizado corretamente.

2 Estudo da Taxa de Aprendizagem

Foi implementada uma Rede Adaline utilizando treinamento baseado na regra Delta. O objetivo desta etapa consistiu em analisar o comportamento da convergência da função de perda para diferentes valores da taxa de aprendizagem η . Foram avaliados os seguintes valores:

$$\eta \in \{10^{-4}, 10^{-3}, 10^{-2}, 5 \times 10^{-2}, 10^{-1}\}$$

Em todos os experimentos, manteve-se fixo o número máximo de épocas em $N = 200$. Os resultados obtidos são apresentados na Tabela 1.

Taxa de Aprendizagem	Custo Final	Épocas Executadas
10^{-4}	0,190734	200
10^{-3}	Overflow/Divergência	200
10^{-2}	Overflow/Divergência	112
5×10^{-2}	Overflow/Divergência	74
10^{-1}	Overflow/Divergência	65

Tabela 1: Resultados para diferentes taxas de aprendizagem

Observou-se que apenas a taxa $\eta = 10^{-4}$ apresentou comportamento estável durante todo o treinamento. O custo inicial foi aproximadamente 0,499400 e o custo final atingiu 0,190734, correspondendo a uma redução de aproximadamente 61,81%.

Para taxas maiores, especialmente a partir de 10^{-3} , o treinamento apresentou crescimento explosivo da função de perda, ocasionando *overflow* numérico. Esse comportamento indica divergência do processo de otimização, causada por atualizações excessivamente grandes nos pesos da rede.

As taxas $\eta = 10^{-2}$, 5×10^{-2} e 10^{-1} interromperam o treinamento antes das 200 épocas devido à explosão numérica da função custo. Embora taxas maiores possam acelerar inicialmente a convergência, neste problema específico elas tornaram o treinamento instável. Assim, o melhor

valor selecionado foi:

$$\eta = 10^{-4}$$

pois proporcionou convergência suave, estável e o menor valor final da função de perda.

3 Treinamento e Avaliação do Modelo

Após selecionar a melhor taxa de aprendizagem, a Rede Adaline foi treinada novamente utilizando:

- Taxa de aprendizagem: $\eta = 10^{-4}$
- Número máximo de épocas: 200

O treinamento executou todas as 200 épocas previstas, atingindo custo final igual a 0,190734. Em seguida, o modelo foi avaliado no conjunto de teste. A acurácia global obtida foi:

$$\text{Acurácia} = 95,77\%$$

As métricas de precisão, recall e F1-score para a classe *good* (+1) foram:

Classe	Precisão	Recall	F1-score
good (+1)	0,9388	1,0000	0,9684

Tabela 2: Métricas de desempenho da Rede Adaline

A matriz de confusão obtida é apresentada na Tabela 3.

		Classificação Real	
		good (+1)	bad (-1)
Previsto	good (+1)	46	3
	bad (-1)	0	22

Tabela 3: Matriz de confusão da Rede Adaline

Observa-se que a Rede Adaline conseguiu classificar corretamente todas as 46 amostras reais da classe *good*. Além disso, classificou corretamente 22 amostras da classe *bad*, cometendo apenas 3 erros no total.

Os resultados demonstram que o modelo apresentou excelente capacidade de generalização para o problema de classificação ionosférica.

4 Discussão e Conclusão

A normalização utilizando Z-score mostrou-se essencial para a estabilidade da regra Delta. Como a atualização dos pesos depende diretamente dos valores de entrada, atributos com magnitudes muito diferentes poderiam provocar gradientes desbalanceados e oscilações no treinamento. A padronização garantiu estabilidade numérica e melhor comportamento da convergência.

Em relação às taxas de aprendizagem, observou-se que valores muito altos provocaram divergência da função de custo. As taxas 10^{-2} , 5×10^{-2} e 10^{-1} produziram crescimento explosivo do erro, levando a overflow numérico. Por outro lado, a taxa 10^{-4} proporcionou aprendizado mais lento, porém estável e consistente, resultando no menor custo final.

A Rede Adaline apresentou desempenho bastante elevado no conjunto de teste, atingindo acurácia global de aproximadamente 95,77%. As métricas de precisão, recall e F1-score também indicaram excelente capacidade de classificação.

Considerando uma aplicação real de monitoramento ionosférico, o erro mais crítico seria classificar uma amostra *bad* como *good*. Esse tipo de erro corresponde ao caso em que o sistema identifica incorretamente a presença de estrutura ionosférica coerente quando, na realidade, há falha de transmissão ou interferência. Em aplicações reais de telecomunicações e navegação, esse erro poderia levar sistemas operacionais a assumirem condições adequadas de propagação do sinal, causando falhas de comunicação, perda de dados ou tomada incorreta de decisões.

Portanto, minimizar falsos positivos da classe *good* é fundamental para garantir confiabilidade operacional em sistemas automáticos de monitoramento ionosférico.

De maneira geral, conclui-se que a Rede Adaline mostrou-se adequada para este problema de classificação binária. O modelo apresentou alta acurácia, baixa taxa de erro e boa estabilidade quando utilizada uma taxa de aprendizagem apropriada. Além disso, a simplicidade da Adaline permite interpretação relativamente intuitiva do processo de treinamento, tornando-a uma alternativa eficiente para problemas lineares de classificação supervisionada.